

به نام خدا

گزارش تمرین کامپیوتری

شماره پنج

هوش مصنوعی

محمد صدرا عباسی - ۸۱۰۱۰۱۴۶۹

پیش پردازش

کلاس TextPreProc:

به طور کلی این کلاس ترکیبی از چند عملیات پیش پردازش را روی یک متن ورودی انجام می دهد که شامل: حذف لینک ها و منشن ها - حذف کاراکتر های نویزی مانند ساختار های html و حروف غیر الفبایی - حذف stopword های انگلیسی - ریشه یابی کلمات استفاده شده بر اساس متدی که مشخص شده که می تواند lemmatization یا stemming باشد

سوالات:

- دلیل انجام پیش پردازش روی داده های متنی

داده های اولیه متنی معمولا شامل کاراکتر های نویزی است که کمکی به خوشه بندی محتوایی نمی کنند و هم در مدل خطا ایجاد می کنند

از آنجایی هر کلمه یکتا در داده متنی به عنوان یک بعد یا ویژگی در نظر گرفته می شود، وجود stopword ها ابعاد این ماتریس را زیاد می کند و باعث پردازش اضافی و بی فایده می شود

کلماتی که ریشه و مفهوم یکسانی دارند ممکن است به دلیل ساختار جمله یا شکل نوشتاری متفاوت به شکل های متفاوتی در متن وجود داشته باشند در این صورت مدل نباید به اشتباه آنها را به عنوان کلمات متفاوت در نظر بگیرد

- تفاوت stemming و lemmatization به همراه مزایا و معایب هر کدام

روش	stemming	lemmatization
کارکرد	برای ایجاد ریشه، انتهای کلمات را حذف می کند مثل حذف ing	برای پیدا کردن ریشه، کلمات را در دیکشنری جستجو می کند
مزایا	سادگی و سرعت بیشتر	ایجاد کلمات معنا دار و هوشمندی بیشتر
معایب	بی دقت تر است چون ممکن است یک کلمه بی معنا تولید کند مثلا: Happily -> happi	کند تر است چون نیازی به جستجو در دیکشنری دارد و همچنین نیازی به دیتا بیس


- چرا استخراج ویژگی ضروری است و نمی‌توان مستقیماً از متن خام برای خوشه‌بندی استفاده کرد؟

الگوریتم‌های خوشه‌بندی بر اساس فاصله هندسی کار می‌کنند بنابراین نمی‌توان از داده‌های متنی در این الگوریتم‌ها استفاده کرد و باید آنها را به عدد تبدیل کرد


- کدام روش یا ترکیب روش‌های پیش‌پردازش عملکرد بهتری داشته است؟

برای بررسی عملکرد هر روش، ماکزیمم امتیاز Silhouette Score مدل K-means را برای هر کدام حساب کرده و مقایسه می‌کنیم:

Preprocess + Lemmatization:



Preprocess + Stemming:



با مقایسه ماکزیمم امتیازها که برای روش اول 0.16 و برای روش دوم 0.14 است نتیجه می‌گیریم روش اول عملکرد بهتری دارد

فرایند حل مسئله

کلاس Vectorization:

وظیفه اصلی این کلاس تبدیل داده های متنی به داده های عددی است که در الگوریتم ها استفاده می شوند. ابتدا `extract_fields` فراخوانی می شود با استفاده از `regular expression` متن اصلی و خلاصه متن (که با `text` و `summary` در داده های خام وجود دارند) را استخراج می کند و در یک ستون مجزا در دیتا فریم قرار می دهد. سپس روی این دو ستون جدید از متد `process_text` (از کلاس `TextPreProc`) استفاده می شود تا پیش پردازش روی این دو ستون انجام شود و این داده های پیش پردازش شده دوباره در ستون های جدیدی از دیتا فریم قرار می گیرند. چیزی که به عنوان داده نهایی برای ورودی دادن به مدل `all-MiniLM-L6-v2` در نظر گرفته می شود، ترکیبی از خلاصه و متن پیش پردازش شده برای هر سطر است که به این شکل ترکیب می شوند : `text . summary` و در ستون جدیدی قرار می گیرند.

مدل متن های این ستون را `encode` کرده یک بردار متراکم با ابعاد ۳۸۴ تولید می کند خروجی های کلاس : دیتا فریم ساخته شده در پایپ لاین + ماتریس ویژگی ها به ابعاد $N*384$

K-means Clustering:

کلاس KMeansClustering:

به طور کلی هدف این کلاس اجرای الگوریتم K-means است که این پیاده سازی توسط کلاس `KMeans` در کتابخانه `Scikit-Learn` انجام شده و به هنگام `instance` گرفتن از آن باید چند پارامتر مهم را تعیین کنیم:

- `n_clusters` : برای تعداد خوشه هاست
- `init` : روش مقدار دهی اولیه را مشخص می کند اگر `'random'` باشد نقاط تصادفی را به عنوان مرکز خوشه ها انتخاب می کند و اگر `'++k-means'` باشد مراکز اولیه را به صورت با فاصله زیاد از هم انتخاب می کند که باعث تسریع فرایند همگرایی الگوریتم می شود
- `n_init` : تعیین می کند که الگوریتم چند بار با `seed` های مختلف اجرا شود (در نهایت مدلی که کمترین میزان خطا `sse` را داشته بر می گرداند)
- `max_iter` : حداکثر تکرار الگوریتم در صورت عدم همگرایی را تعیین می کند

این کلاس شامل اجزای اصلی زیر است:

متد `evaluate_k`: الگوریتم K-means را برای یک رنج مشخص از k اجرا می کند و در هر تکرار دو معیار `SSE` و `Silhouette Score` را محاسبه می کند

متد `plot_result`: نتایج عددی حاصل از متد قبلی را `plot` می کند تا برای تصمیم گیری درباره مقدار هایپر پارامتر ها از آن استفاده کنیم

متد `model`: این متد مدل K-means را روی داده ها و با استفاده از k ای که ورودی گرفته آموزش می دهد و `label` های نهایی را برای هر داده بر می گرداند


پارامتر ها:

K : تعداد خوشه ها یا مراکز

معیار انتخاب مقدار پارامتر ها:

برای پیدا کردن k مناسب از معیار `SSE` استفاده شده که مجموع مربع خطاها را محاسبه می کند، منظور از خطا، فاصله هر داده از مرکز خوشه خود است مراحل ارزیابی به این شکل است که برای یک رنج از مقادیر k الگوریتم را اجرا می کنیم و میزان `SSE` را ذخیره می کنیم در ادامه با `plot` کردن این مقادیر و با استفاده از روش `elbow`، مقدار بهینه برای k را تخمین می زنیم

نمودار `SSE/k`:



با توجه به plot خروجی مقدار ۳ برای k همان نقطه شکستگی است که طبق elbow method می تواند انتخاب مناسبی برای k باشد البته ۴ هم به نوعی می تواند elbow باشد برای قضاوت نهایی بین انتخاب ۳ یا ۴ از معیار Silhouette استفاده کردیم که برای $k = 3$ مقدار بیشتری دارد

DBSCAN Clustering:

کلاس DBSCANClustering:

این کلاس الگوریتم DBSCAN را با استفاده از کتابخانه Scikit-Learn اجرا می کند و برای اجرای آن باید ابتدا دو پارامتر را مشخص کرد: eps یا همان شعاع همسایگی نقاط و همچنین min_samples یعنی حداقل نقاطی که باید در همسایگی یک نقطه وجود داشته باشند تا آن نقطه تبدیل به یک core point یا خوشه شود

این کلاس شامل اجزای اصلی زیر است:

متد evaluate_params: یک گرید سرچ روی تمام ترکیبات اعضای دامنه eps و min_samples انجام می دهد و در هر step مقدار امتیاز Silhouette و همچنین نرخ داده های نویز و تعداد خوشه ها را محاسبه می کند. از این متد برای پیدا کردن مقدار مناسب برای پارامتر های مدل استفاده می کنیم

متد model: این متد مدل DBSCAN را روی داده ها و با استفاده از eps و min_samples ای که ورودی گرفته آموزش می دهد و label های نهایی را برای هر داده بر می گرداند

پارامتر ها:

Eps : شعاع همسایگی نقاط

Min_samples: حداقل نقاطی که باید در همسایگی وجود داشته باشند تا آن نقطه تشکیل یک خوشه دهد. اگر این تعداد را کم درنظر بگیریم تعداد زیادی خوشه کوچک خواهیم داشت و اگر بزرگ درنظر بگیریم خوشه های کم و نویز های زیاد خواهیم داشت بنابراین هدف برقراری تعادل بین داده های نویز و تعداد و جمعیت خوشه هاست

معیار انتخاب مقدار پارامتر ها:

در واقع برای پیدا کردن مقادیر بهینه باید تعدادی معیار را به صورت همزمان مورد ارزیابی قرار دهیم برای این کار از یک گرید سرچ برای تست کردن حالات مختلف استفاده شده و هدف این است که

مقادیری را پیدا کنیم که به ازای آنها داده های نویز کمی داشته باشند در حالی که امتیاز Silhouette نسبتاً بالا باشد در واقع باید به یک تعادل مناسب بین این دو معیار برسیم از طرفی تعداد خوشه ها باید معقول باشد نه آنقدر زیاد که خوشه بندی بی معنا شود و تحلیل روی آنها دشوار باشد و نه آنقدر کم که خوشه بندی خاصی وجود نداشته باشد.

نتیجه تست برای مقادیر دامنه:

```
eps_values = [0.1 , 0.2 ,0.3, 0.4, 0.5, 0.6, 0.7 , 0.8 , 0.9]
min_samples_values = [3, 4, 5, 6 ,7, 8, 9, 10]
```

با توجه به بررسی نتایج بدست آمده بهترین انتخاب $\text{eps} = 0.7$ و $\text{min_points} = 6$ است که به ازای آن خوشه بندی به صورت زیر خواهد بود:

Eps	Min_S	Clusters	Noise(%)	Silhouette
0.70	6	3	32.9 %	0.0838

Hierarchical Clustering:

کلاس HierarchicalClustering:

این کلاس الگوریتم خوشه بندی سلسله مراتبی را با استفاده از کتابخانه Scikit-Learn پیاده سازی و ارزیابی می کند. رویکرد تجمعی یا Agglomerative برای اجرای الگوریتم پیاده سازی شده که در آن خوشه ها از پایین به بالا ادغام می شوند

اجزای اصلی کلاس:

متد `plot_dendrogram`: این متد وظیفه رسم و نمایش نمودار دندروگرام را بر عهده دارد که با استفاده از آن نحوه ادغام خوشه ها و فواصل ادغام را مشاهده و ارزیابی می کنیم. محور عمودی نمودار فاصله ادغام و محور افقی سمپل های هر خوشه است

متد `evaluate_methods`: این متد ترکیب های مختلف از معیار های پیوند و توابع فاصله را ارزیابی می کند و برای هر ترکیب امتیاز Silhouette را محاسبه می کند تا به بهترین ترکیب برسیم

مدل نهایی را با پارامتر های بهینه آموزش می دهد و برچسب های خوشه بندی را برمی گرداند

پارامتر ها:

N_clusters: تعداد خوشه هایی که نهایتا با ادغام های مرحله به مرحله باید بوجود بیایند

linkage: معیار ادغام خوشه ها را تعیین می کند. یعنی مشخص می کند فاصله بین دو "خوشه" چگونه محاسبه شود تا تصمیم بگیریم کدام دو خوشه باید با هم یکی شوند که می تواند یکی از حالات زیر باشد:

Average: فاصله بین دو خوشه برابر است با میانگین فاصله بین تمام جفت نقاط موجود در آن دو خوشه.
Ward: این روش به جای محاسبه فاصله هندسی مستقیم، سعی می کند واریانس (Variance) درون خوشه ها را حداقل کند. یعنی دو خوشه ای را ادغام می کند که ادغامشان کمترین افزایش را در واریانس کل ایجاد کند.
Complete: فاصله بین دو خوشه برابر است با فاصله بین دورترین نقاط آن دو خوشه.
Single: فاصله بین دو خوشه برابر است با فاصله بین نزدیکترین نقاط آن دو خوشه.


Metric: نوع تابع فاصله را تعیین می کند که می تواند یکی از حالات زیر باشد:

Euclidean: فاصله مستقیم بین دو نقطه در فضا را محاسبه می کند.
Cosine: این معیار به جای اندازه گیری فاصله فیزیکی، کسینوس زاویه بین دو بردار را محاسبه می کند.
Manhattan: مجموع قدر مطلق تفاضل ها را در هر بعد محاسبه می کند

معیار انتخاب مقدار پارامتر ها:

برای یافتن مقدار مناسب **n_clusters** باید نمودار **dendrogram** را ارزیابی کنیم و طولانی ترین خط عمودی را (که ادغامی در طول آن صورت نگرفته) پیدا کنیم. سپس تعداد شاخه هایی که در تقاطع فرضی میانه این فاصله قرار دارند را به عنوان **n** انتخاب می کنیم، منطق انتخاب این است که فاصله خوشه ها در این حالت از هم زیاد بوده که در فاصله نسبتا طولانی ادغام صورت گرفته پس توقع داریم خوشه هایی نسبتا متراکم داشته باشیم که فاصله زیادی از هم دارند و این کاملا برای خوشه بندی مطلوب است

نمودار dendrogram:



با توجه به این نمودار و منطق قبلی طولانی ترین خط عمودی بدون ادغام مربوط به بازه تقریباً ۶ تا تقریباً ۲۱ می شود که در این بازه، هر خط برش فرضی می تواند تعداد خوشه های متفاوتی (از ۲ تا ۷ خوشه) را پیشنهاد دهد. با این حال، مقدار $n=3$ انتخاب شد؛ زیرا در این سطح فاصله ادغام بعدی خوشه ها نسبتاً بیشتر است تا مقادیر دیگر که نشان دهنده جدایی مطلوب تر است.

برای پیدا کردن مقدار مناسب پارامترهای دیگر نیز، باید ترکیب های مختلف آنها را ارزیابی کرده و ترکیبی را انتخاب کنیم که به ازای آن بیشترین امتیاز Silhouette بدست آمده

نتیجه بررسی:

```
Method: ward, Metric: euclidean, Silhouette Score: 0.1572
Method: complete, Metric: euclidean, Silhouette Score: 0.1003
Method: complete, Metric: cosine, Silhouette Score: 0.1003
Method: complete, Metric: manhattan, Silhouette Score: 0.0796
Method: average, Metric: euclidean, Silhouette Score: 0.1308
Method: average, Metric: cosine, Silhouette Score: 0.0816
Method: average, Metric: manhattan, Silhouette Score: 0.1410
Method: single, Metric: euclidean, Silhouette Score: 0.0975
Method: single, Metric: cosine, Silhouette Score: 0.0975
Method: single, Metric: manhattan, Silhouette Score: 0.0975
```

با توجه به مقادیر بدست آمده بهترین مقدار برای این هاپیر پارامتر ها ترکیب زیر است:

Method: ward, Metric: euclidean, Silhouette Score: 0.1572

سوالات:

- روش های supervised learning و unsupervised learning را توضیح دهید و با هم مقایسه کنید
- در یادگیری با نظارت، داده های ورودی برچسب خورده هستند و هدف اصلی مدل یادگیری روابط بین داده های ورودی و برچسب هاست اما در یادگیری بدون نظارت، داده های ورودی بدون برچسب هستند و هدف مدل کشف کردن الگو ها، ساختار ها و گروه بندی داده ها به صورت خودکار است
- دلیل استفاده از بردار های ویژگی چیست؟ ویژگی های این بردار ها چیست
- بردار سازی در واقع یک متن را به یک فضای برداری نگاشت می کند و علت اصلی آن این است که مدل بتواند شباهت های معنایی را از طریق محاسبه فواصل هندسی کشف کند و بدیهی است که محاسبات روی متن امکان پذیر نیست.
- ویژگی ها: طول بردارها ثابت است / کلماتی که از نظر معنایی نزدیک تر اند، در این فضای برداری نیز بهم نزدیک تر اند / مقادیر بردار ها به صورت پیوسته و فشرده است

- روش های برداری سازی متن را توضیح دهید و آنها را از نظر کیفیت معنایی مقایسه کنید

Bag of words: متن را بر اساس تکرار کلمات بردار سازی می کند. از آنجایی که ترتیب کلمات را در نظر نمی گیرد کیفیت نسبتاً پایین تری دارد

TF-IDF: این روش هم مثل bag of word عمل می کند یعنی ابتدا بررسی می کند که هر کلمه چندبار در متن تکرار شده اما در ادامه بررسی می کند یک کلمه در کل چقدر کمیاب است و بر اساس آن به کلمات وزن می دهد و با این کار ارزش کلماتی که زیاد در متن تکرار شده اند اما فاقد ارزش معنایی هستند را کم می کند. به نسبت bag of words بهتر است اما همچنان به دلیل در نظر نگرفتن ترتیب کلمات کیفیت پایینی دارد

Word embeddings: هر کلمه را به بردار متراکمی تبدیل می کند که معنای آن کلمه را درون خود دارد. در واقع می تواند به کلمات معنا دهد اما آن را در زمینه جمله نمی فهمد یعنی ممکن است کلمه در جمله معنای متفاوتی دهد اما این روش متوجه این تغییر نمی شود. کیفیت بهتری نسبت به دو روش قبل دارد و می توان گفت کیفیت آن متوسط است

Sentence embedding: هم ترتیب کلمات و هم زمینه جمله را برای برداری سازی در نظر می گیرد در نتیجه بالاترین کیفیت را دارد

- درباره مدل های Sentence Transformer و all-MiniLM-L6-v2 توضیح دهید

Sentence Transformer: این مدل بجای اینکه برای هر کلمه یک بردار مستقل بسازد، کل کلمات جمله را باهم ترکیب کرده و یک بردار واحد با طول ثابت تولید می کند که حاوی مفهوم کلی جمله است برای اینکار از ساختاری بنام شبکه های دوقلو استفاده می کند که این شامل دو شبکه عصبی کاملاً یکسان است و دو جمله ورودی را به موازات هم پردازش می کنند. اینکار برای محاسبه سریع میزان شباهت معنایی متون است

- all-MiniLM-L6-v2:

All: این مدل رو مجموعه بسیار عظیمی از متون مختلف آموزش داده شده است.

miniLm: این مدل بر اساس تکنیک «تقطیر دانش» (Knowledge Distillation) ساخته شده است. در این تکنیک، دانش و الگوهای یادگیری یک مدل بسیار بزرگ، پیچیده و کند (مدل استاد/Teacher)، فشرده سازی شده و به یک مدل کوچکتر (مدل شاگرد/Student) منتقل می شود. با این کار، مدل کوچکتر عملکردی نزدیک به مدل بزرگ (حفظ بیش از ۹۰٪ دقت) را با حجم و مصرف منابع بسیار کمتر

ارائه می‌دهد

L6: این شبکه عصبی از ۶ لایه پردازشی تشکیل شده

خروجی مدل: با ورودی گرفتن متن (با هر طولی)، آن را به یک فضای برداری با طول ثابت 384 نگاشت می‌کند که این بردار حاوی معنای دقیق آن جمله در فضای ریاضی است

- روش elbow method چیست و چگونه از آن برای انتخاب تعداد خوشه‌ها استفاده می‌شود

در این روش، K-means برای بازه‌ای از مقادیر k اجرا می‌شود و در هر اجرا مجموع مربعات فاصله هر نقطه از مرکز خوشه آن محاسبه می‌شود که به آن SSE می‌گوییم. سپس با ساختن نمودار SSE_K که در واقع محور عمودی آن SSE و محور افقی آن K هست دنبال نقطه‌ای می‌گردیم که شیب تابع از حالت خیلی تند به حالت کند تغییر کند، این نقطه تعادل مناسبی بین مینیمم سازی خطا و پیچیدگی مدل برقرار می‌کند

- روش‌های خوشه‌بندی استفاده شده را توضیح دهید


K-Means: الگوریتمی افزایی که داده‌ها را به K خوشه مجزا تقسیم می‌کند. نقاط را به نزدیک‌ترین مرکز اختصاص داده و مراکز را به صورت تکرار شونده تا همگرایی کامل به‌روزرسانی می‌کند. به تعداد خوشه اولیه نیاز دارد، فرض می‌کند خوشه‌ها کروی هستند و به شدت تحت تأثیر داده‌های پرت قرار می‌گیرد.


DBSCAN: الگوریتمی که نقاط متراکم را به هم متصل کرده و خوشه‌هایی با اشکال هندسی نامنظم می‌سازد. به جای دریافت تعداد خوشه، دو پارامتر eps (شعاع همسایگی) و min_samples (حداقل نقاط لازم برای تشکیل یک ناحیه متراکم) را دریافت می‌کند. بزرگترین مزیت آن شناسایی داده‌های دورافتاده (پراکنده) و حذف آن‌ها به عنوان نویز (برچسب -1) است.

Hierarchical Clustering: الگوریتمی که از پایین به بالا کار می‌کند. ابتدا هر نقطه یک خوشه مجزا فرض می‌شود. در هر مرحله، شبیه‌ترین خوشه‌ها بر اساس یک تابع فاصله و یک معیار پیوند با هم ادغام می‌شوند تا در نهایت یک ساختار درختی به نام دندروگرام ساخته شود.

کاهش بعد

در این بخش از دو روش PCA و MDS برای کاهش بعد داده ها استفاده شده. با این دو روش نتایج خوشه بندی الگوریتم های قبلی روی داده های ۳۸۴ بعدی به صورت زیر خواهد بود:





مقایسه الگوریتم های خوشه بندی : می توان مشاهده کرد که دو الگوریتم K-means و Hierarchical تا حد زیادی خوشه بندی مشابه انجام داده اند و به طور کلی داده ها را در ۳ خوشه مجزا تشخیص داده اند. همچنین بدلیل Hard clustering بودن این الگوریتم ها، همه داده ها به یکی از ۳ خوشه مپ شده اند. از طرفی DBScan رفتار منحصر بفردی از خود نشان داده است، در نواحی ای که تراکم زیادی از داده ها وجود داشته، هر داده به یکی از ۳ خوشه اصلی تعلق یافته اما در نواحی اطراف آنها که تراکم کمتر بوده داده های زیادی را به عنوان نویز تشخیص داده است

سوالات:

- درباره PCA تحقیق کرده و نحوه عملکرد آن را توضیح دهید

هدف اصلی این روش این است که ابعاد داده ها را طوری کاهش دهد که بیشترین اطلاعات و تفاوت های بین داده های حفظ شود و اینکار را از طریق یک تبدیل خطی انجام می دهد:

- ۱- محاسبه میانگین همه داده ها و انتقال محور های مختصات به مرکز ثقل داده ها
- ۲- پیدا کردن محوری که وقتی داده ها روی آن تصویر می شوند بیشترین گستردگی را داشته باشند
- ۳- پیدا کردن محوری که دقیقا به محور اول عمود باشد و بیشترین پراکندگی باقی مانده را توضیح دهد
- ۴- برای هر داده تنها مختصات آن روی این دو مولفه ۲ و ۳ به عنوان ابعاد جدید نگه داشته می شود

- عملکرد دو روش کاهش بعد استفاده شده را مقایسه کنید

روش PCA مبتنی بر واریانس است و برای پیدا کردن محور های اصلی، ساختار کلی داده ها را در نظر می گیرد در نتیجه محور هایی را می سازد که تفاوت های بزرگ داده ها روی آن محور ها برجسته تر باشد اما روش MDS بر اساس فواصل هندسی کار می کند و با محاسبه فاصله هندسی تک تک داده ها در فضای ۳۸۴ بعدی، نقاط را طوری در فضا توزیع می کند که فاصله آنها تا حد امکان حفظ شود و مانند فضای اصلی ۳۸۴ بعدی باقی بماند.

در نتیجه منطق عملکرد این دو روش مشاهده می شود که PCA توانسته ۳ ناحیه کاملاً مجزا و با فاصله زیاد از هم را نشان دهد اما روش MDS داده ها به شکل پیوسته تری در ۳ ناحیه اصلی توزیع شده اند و دلیل این موضوع پیوستگی معنایی ذاتی داده های متنی است و این روش سعی کرده تا حد امکان توزیع نزدیک به واقعیت را برای ما تصویر کند

ارزیابی

معیار های ارزیابی:

Silhouette: این معیار کیفیت خوشه بندی را بر اساس دو مفهوم زیر اندازه گیری می کند

انسجام: نزدیکی داده های داخل یک خوشه

تفکیک: دوری داده های داخل خوشه های مجاور

برای هر داده i این دو مقدار حساب می شود:

$a(i)$: میانگین فاصله i از همه نقاط دیگر در همان خوشه

$b(i)$: کمترین میانگین فاصله نقطه i از تمام نقاط موجود در نزدیکترین خوشه همسایه (خوشه ای که نقطه i به آن تعلق ندارد).

$$s(i) = [b(i) - a(i)] / \max(a(i), b(i))$$

امتیاز کل مدل برابر میانگین $s(i)$ برای تمام نقاط است که مقدار آن بین -1 و 1 می تواند باشد. هرچه به یک نزدیکتر باشد یعنی خوشه بندی بهتر است

همگنی (Homogeneity Score): معیار همگنی یک ارزیابی بیرونی است. یک خوشه‌بندی زمانی کاملاً همگن است که هر خوشه فقط و فقط شامل داده‌هایی باشد که در واقعیت متعلق به یک کلاس واحد هستند.

فرمول محاسبه:

$$h = 1 - [H(C|K)/H(C)]$$


$H(C|K)$: آنتروپی شرطی کلاس‌های واقعی به شرط خوشه‌های پیش‌بینی شده

$H(C)$: آنتروپی کلاس‌های واقعی

می‌توان نتیجه گرفت که استفاده از این معیار به دلیل عدم دسترسی به برچسب‌های واقعی امکان‌پذیر نیست.

مقایسه حالت خوشه‌بندی برای داده‌های 2d و 384d:

Algorithms	Silhouette Score (384d)	Silhouette Score (2d)
K-Means	0.1594	0.7249
Hierarchical	0.1572	0.7243
DBSCAN	0.1993	0.579



با توجه به مقادیر جدول، اختلاف زیادی بین امتیازات دو فضا وجود دارد؛ اما این اختلاف لزوماً به دلیل کیفیت خیلی بالاتر خوشه‌بندی یا درک عمیق‌تر مدل نیست. در فضای ۳۸۴ بعدی، مدل با داده‌هایی کار می‌کند که پیچیدگی بالایی دارند و مرزهای معنایی متن‌ها معمولاً به صورت درهم‌تنیده هستند که منجر به امتیاز کلی پایین‌تر برای آن‌ها می‌شود. اما الگوریتم PCA، فضای داده‌ها را به ۲ بُعد فشرده می‌کند و با این کار بخش زیادی از اطلاعات و پیچیدگی‌های طبیعی متن را دور می‌ریزد. در نتیجه، توزیع داده‌ها (با توجه به نمودار بالا) به شکل غیرطبیعی به سه ناحیه کاملاً متراکم و با فاصله زیاد از هم درمی‌آید. این مسئله باعث افزایش امتیاز سیلوئت به‌طور مصنوعی می‌شود، در حالی که مدل در این حالت عمق معنایی جملات را از دست داده است.

بررسی خوشه‌های حاصل از هر الگوریتم:

KMeans:

خوشه ۰: تمرکز بر روی بهداشت دهان و دندان سگ

1. my pooch love them... keep his teeth clean
2. great product... cleaned my dog teeth
3. great product for your dog... help keep your dog teeth clean
4. great treat... improving their tooth health

خوشه ۱: تنقلات غذایی انسانی

1. quaker soft baked oatmeal cookie...
2. salt and vinegar chip...
3. pop chips... low calorie
4. soft baked cookies...

خوشه ۲: روغن نارگیل

1. i use it for my hair and skin...
2. body/face/hair moisturizer...
3. health benefits of coconut oil...
4. excellent hair conditioner...

DBScan:

خوشه ۰: تمرکز بر روی بهداشت دهان و دندان سگ

1. My Pooch loves them
2. great product
3. Great product for your dog !
4. Great treat for you dog while improving their tooth health

خوشه ۱: تنقلات غذایی انسانی

1. Quaker soft baked oatmeal cookie
2. great chips
3. Soft Baked cookies
4. Not tasty

خوشه ۲: روغن نارگیل

1. The best there is...
2. Wow where has coconut oil been all my life - just Google the health benefits and be amazed!
3. The body loves coconut oil
4. EXCELLENT Hair Conditioner - Blonde Hair

خوشه ۱- (نویز): این خوشه شامل داده هایی است که محتوای آنها عمومی بوده و بر روی موضوع خاصی تمرکز ندارد اما برخی نمونه ها می توانستند متعلق به خوشه های اصلی باشند در واقع در مرز چگالی قرار گرفته بودند.

1. Not my cup of tea
2. A little pricey, but worth the \$
3. frhgthyrfedws yeyeyey
4. Small dog loves these. They don't last long.

Hierarchical:

خوشه ۰: تنقلات و اسنک انسانی

1. Quaker soft baked oatmeal cookie
2. Not my cup of tea
3. great chips
4. Soft Baked cookies

خوشه ۱: روغن نارگیل + داده های کلی یا نویزی

1. frhgthyrfedws yeyeyey
2. The best there is...
3. Wow where has coconut oil been all my life - just Google the health benefits and be amazed!
4. Finally!!! Amazing result!!!

خوشه ۲: بهداشت دهان و محصول سگ

1. My Pooch loves them
2. great product
3. Great product for your dog !
4. Great treat for you dog while improving their tooth health

بهترین خوشه از نظر عملکرد: انتخاب بهترین روش در این مسئله، کاملاً بستگی به این دارد که ویژگی "Hard Clustering" برای ما مهم باشد یا خیر. اگر الزامی وجود داشته باشد که هر داده دقیقاً به یکی از خوشه‌ها اختصاص یابد و هیچ متنی بدون برچسب نماند، K-Means بهترین انتخاب خواهد بود؛ زیرا همان‌طور که در نمودارها و محاسبه امتیاز سیلوئت مشاهده شد، از انسجام درونی و تفکیک‌پذیری بسیار مناسبی در پوشش‌دهی کل داده‌ها برخوردار است. اما اگر نخواهیم هر داده لزوماً در یک خوشه قرار بگیرد و این مسئله را بپذیریم که داده‌های مرزی و مبهم به عنوان نویز (Noise) کنار گذاشته شوند، در این صورت DBSCAN عملکرد بسیار برجسته‌ای دارد. این الگوریتم با فیلتر کردن داده‌های حاشیه‌ای و تشخیص آن‌ها به عنوان نویز، انسجام درونی هسته‌ی خوشه‌ها را کاملاً حفظ می‌کند و این خلوص بالا، خود را در امتیاز سیلوئت بیشتر این الگوریتم به خوبی نشان می‌دهد.